

데이터 전처리

- 데이터 탐색
- 결측치 처리
- 이상치 처리
- Feature Engineering
- 파이썬 코딩 실습

Data Pre-Processing


수집한 데이터를
데이터 분석 / AI 모델링을 위하여
데이터를 정제하고 다듬는 작업

데이터 탐색하기

결측치 처리하기

이상치 처리하기

Feature Engineering



What data scientists spend the most time doing


- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

데이터 탐색하기(1/4)



Sample 데이터를 육안으로
확인하여 데이터의 구성과
필요 유무에 대한 확인

`head(), tail()`



수치 데이터에 대한
수학적 특성 확인으로
데이터 분포 확인

`describe()`



컬럼 수, 데이터 타입 등을
확인하여 정상적 로드 확인

`info()`

Data Frame 정보 확인 ... Dataframe명.info()

```
dataframe.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 9930 entries, 0 to 9929
```

```
Data columns (total 5 columns):
```

#	Column	Non-Null Count	Dtype
0	column1	9930 non-null	object
1	column2	9930 non-null	object
2	column3	9930 non-null	float64
3	column4	9930 non-null	float64
4	column5	9930 non-null	float64

	column1	column2	column3	column4	column5
0	C	F	2640.0000	0.0	0.0000
1	-	-	300.0000	0.0	0.0000
2	E	F	16840.0000	0.0	6983.0000
3	F	F	15544.7334	0.0	6750.4666
4	D	M	4700.0000	0.0	4502.0000

데이터 탐색하기(3/4)

Data Frame 앞 5개 데이터 확인 ... Dataframe명.head()

```
dataframe.head()
```

	column1	column2	column3	column4	column5
0	C	F	2640.0000	0.0	0.0000
1	-	-	300.0000	0.0	0.0000
2	E	F	16840.0000	0.0	6983.0000
3	F	F	15544.7334	0.0	6750.4666
4	D	M	4700.0000	0.0	4502.0000

Data Frame 뒤 5개 데이터 확인 ... Dataframe명.tail()

```
dataframe.tail()
```

	column1	column2	column3	column4	column5
9925	C	F	1296.0999	0.0	643.1001
9926	G	M	13799.6666	0.0	10605.9266
9927	C	-	1396.2000	1206.0	0.0000
9928	C	F	3140.0000	0.0	0.0000
9929	C	F	2436.9000	0.0	1839.9000

Data Frame 통계데이터 확인 ... Dataframe명.describe()

```
dataframe.describe()
```

		column1	column2	column3	
유효데이터수	count	9.930000e+03	9.930000e+03	9.930000e+03	
	mean	1.181774e+04	1.897536e+03	6.395259e+03	값평균
표준편차	std	1.397822e+05	1.235342e+04	8.346138e+04	
	min	0.000000e+00	0.000000e+00	0.000000e+00	최소값
1사분위값	25%	3.624503e+03	3.240000e+02	1.260000e+03	
	50%	8.284467e+03	1.593307e+03	4.768617e+03	2사분위값(중위값)
3사분위값	75%	1.372000e+04	2.308360e+03	7.982000e+03	
	max	1.281568e+07	1.188998e+06	7.689409e+06	최대값

파이썬 실습

```
(3)-1-데이터전처리.py x
1  """
2  #####
3  Python 활용한 데이터 전처리/시각
4  #####
5  *****
6  Chapter 1. 데이터 전처리
7  데이터 분석/AI 모델링을 위하여 데이터를 정제하는 전처리 방법을 실습해 봅시다.
8  우선 확보한 데이터를 전처리를 위해 불러옵니다.
9  *****
10 """
11
12 # 판다스 불러오기
13 import pandas as pd
14
15
16 # sc_cust_info_txn_v1.5.csv파일을 읽어 데이터를 불러 올 수 있습니다.
17 #개별 환경 사용자
18 df=pd.read_csv("cust_info_file.csv")
19 print(df)
20
21 """
22 -----
23 1. 데이터 탐색하기
24 -----
25
26 1-1 데이터 확인하기
27
28 Dataframe에서 제공하는 메소드를 활용하여 데이터의 구성을 확인합니다.
29 info는 데이터 구성과 특성을 확인해 볼 수 있습니다
30 """
```

결측치(Missing Value)

데이터에 **값이 없는 것**

줄여서

N/A

Null

NaN

Not Available

(does not exist, missing)

empty(null) object

Not a Number

(python)

0(영, Zero)는 결측치 아님

결측치(Missing Value)

데이터를 분석하는데 있어서 반드시 처리해야 하는 값



좋은 성능의 AI 모델을 만드는 데 중요한 요소
추가적인 조사나 정확한 예측을 통해서 결측치를 채워야 함

결측치 처리의 특징

1 실무자의 견해가 많이 반영되는 단계



같은 데이터도 분석가에 따라 결과가 달라질 수도 있고,
잘못될 경우 분석결과가 매우 틀어질 수도 있음

결측치 처리의 특징

2 시간이 많이 투자되어야 함



**데이터 현실을 반영한 결측치 처리가 되어야
분석을 정확하게 진행할 수 있음**

결측치 처리의 특징

3 결측치를 제거하는 것은 가장 쉽게 처리할 수 있는 방법



But,
막대한 데이터 손실 동반

결측치 처리의 특징

4 결측치를 **단순 대체할 경우엔?**



데이터에서 편향(bias)이 생길 수 있음

제거하기

Listwise

User	Device	OS	Used Days
A	Mobile	Android	180
B	Tablet	N/A	360
C	N/A	iOS	384
D	Mobile	iOS	16
E	N/A	N/A	54

▶ 결측치가 존재하는 전체 행 삭제

결측치가 존재하는 B, C, E 유저의 데이터를 삭제하여 결측치 제거

제거하기

Listwise

User	Device	OS	Used Days
A	Mobile	Android	180
B	Tablet	N/A	360
C	N/A	iOS	384
D	Mobile	iOS	16
E	N/A	N/A	54

▶ 결측치가 존재하는 전체 행 삭제

결측치가 존재하는 B, C, E 유저의 데이터를 삭제하여 결측치 제거

제거하기

Pairwise

User	Device	OS
A	Mobile	Android
B	Tablet	N/A
C	N/A	iOS
D	Mobile	iOS
E	N/A	N/A

▶ 결측치로 존재하는 변수만 삭제

모든 변수가 결측치인 경우 해당행 삭제

- 모든 변수가 결측치인 E사용자의 데이터만 제거되고 B와 C는 유지
- 다만, 결측값이 있는 변수는 향후 무시됨

User	Device	OS
A	Mobile	Android
B	Tablet	N/A
C	N/A	iOS
D	Mobile	iOS
E	N/A	N/A

제거하기

Listwise

User	Device	OS	Used Days
A	Mobile	Android	180
B	Tablet	N/A	360
C	N/A	iOS	384
D	Mobile	iOS	16
E	N/A	N/A	54

Pairwise

User	Device	OS	Used Days
A	Mobile	Android	180
B	Tablet	N/A	360
C	N/A	iOS	384
D	Mobile	iOS	16
E	N/A	N/A	54



제거하기 방법을 사용하여 결측치를 처리하면
정보가 손실될 수 밖에 없음



채우기

값 대체하기

User	Used Days
A	180
B	360
C	N/A
D	16
E	54
F	N/A
G	247



User	Used Days
A	180
B	360
C	171
D	16
E	54
F	171
G	247

▶ 결측치를 **평균화 값**으로 대체
가장 널리 사용되는 평균화 값

평균
(mean)

중앙값
(median)

최빈값
(mode)

채우기

예측하기

User	Used Days		User	Used Days
A	180		A	180
B	360		B	360
C	N/A	>	C	188
D	16		D	16
E	54		E	54
F	N/A		F	151
G	247		G	247

▶ 결측치를 상관관계 등을 예측하여 대체

결측치의 특성이 무작위로 관찰되는 것이 아니라고 가정하고, 상관관계나 예측모델을 사용하여 채움

채우기

값 대체하기

User	Used Days
A	180
B	360
C	N/A
D	16
E	54
F	N/A
G	247



User	Used Days
A	180
B	360
C	171
D	16
E	54
F	171
G	247

예측하기

User	Used Days
A	180
B	360
C	N/A
D	16
E	54
F	N/A
G	247



User	Used Days
A	180
B	360
C	188
D	16
E	54
F	151
G	247



결측치를 정보 손실 없이 빠르게 채울 수 있다는 장점



채우기

값 대체하기

User	Used Days
A	180
B	360
C	N/A
D	16
E	54
F	N/A
G	247



User	Used Days
A	180
B	360
C	171
D	16
E	54
F	171
G	247

예측하기

User	Used Days
A	180
B	360
C	N/A
D	16
E	54
F	N/A
G	247



User	Used Days
A	180
B	360
C	188
D	16
E	54
F	151
G	247

But,

모든 결측치가 동일한 값을 가질 수 있음

결측치 처리(15/17)

결측치를 **지정한 값**으로 채우는 메소드
Dataframe명.fillna('standard')

이름	이용상품	이용기간
김тол기	Basic	180
이땡이	N/A	360
박호치	Basic	N/A
최마초	Premium	16
정미미	N/A	54



이름	이용상품	이용기간
김тол기	Basic	180
이땡이	Standard	360
박호치	Basic	Standard
최마초	Premium	16
정미미	Standard	54

결측치 처리(16/17)

결측치를 **같은 간격**으로 채우는 메소드
Dataframe명.interpolate()

이름	이용상품	이용기간
김돌기	Basic	180
이땅이	N/A	360
박호치	Basic	N/A
최마초	Premium	16
정미미	N/A	54



이름	이용상품	이용기간
김돌기	Basic	180
이땅이	N/A	360
박호치	Basic	188
최마초	Premium	16
정미미	N/A	54

결측치 처리(17/17)

결측치가 있는 레코드를 **제거**하는 메소드
Dataframe명.dropna()

이름	이용상품	이용기간
김폴기	Basic	180
이평이	N/A	360
박호치	Basic	N/A
최마초	Premium	16
정미미	N/A	54



이름	이용상품	이용기간
김폴기	Basic	180
이평이	N/A	360
박호치	Basic	N/A
최마초	Premium	16
정미미	N/A	54

파이썬 실습(결측치 처리)

```
E:\AI\CE\시중급교육과정\3-데이터전처리및시각화\3-실습\3-1-데이터전처리.py
(3)-1-데이터전처리.py x
106 cust.info()
107 cust.head()
108
109 '''
110 -----
111 2. 결측치 처리하기
112 -----
113
114 주의!! => 데이터 결측치 처리시 반드시 원본 데이터를 COPY 해서 사용할것!!
115
116 파이썬에서 Copy 메소드를 사용하지 않으면 주소값을 복사해서 사용하기 때문에 원본 값을 변경 시키게 됩니다.
117 따라서 원본 항목을 보전하면서 데이터를 보정하려면 copy 메소드를 사용 해주셔야 합니다.
118 '''
119 # Cust Data 복사
120 cust_fix=cust.copy()
121 cust_fix.head()
122
123 test=cust
124 test.head()
125
126
127 test['age']=0
128 test.head()
129
130 # test 데이터 변경 후 Cust 데이터 확인
131 cust.head()
132
133 #Copy 메소드로 변경한 Cust_fix 데이터 확인
134 cust_fix.head()
135
136 cust=cust_fix.copy()
137
138
139 '''
140 2-1. 결측치 채우기
141 다음은 사용자가 지정하는 단일값으로 채워서 결측치를 처리하는 방법입니다.
142 '''
143
144 '''
145 결측치를 사용할때 특정 숫자나 문자로 결측치를 처리하는 방법
146 '''
```

이상치 처리(1/3)

이데일리 2021년 04월 21일 수요일
세상을 올바르게 세상을 따뜻하게

≡ Q 기업 전자 자동차 생활 산업 중소기업 아웃도어·캠핑 기업일반

'억대 연봉' 신의 직장 70곳 육박...CEO보다 보수 높은 직원도 등장

CXO연구소, 국내 상장사와 주요 비상장사 1700여곳 작년 ...
작년 68곳 임직원 평균 급여 1억 ↑ ... 1·2위 차지
연봉 13%뛼때 고용 1%대 증가 그쳐..."고임금·저고용 현...

등록 2021-04-01 오전 11:00:00
수정 2021-04-01 오전 11:00:00

가 가

2020년 임직원 연간 평균 급여액 상위 TOP 10

[자료:한국CXO연구소, 임직원연평균임금 및 일반 직원 기준, 연간 평균 급여는 전체 임직원을 임직원 수로 나눈 금액]

■ 19년 평균급여 ■ 20년 평균급여




2020년 (주)OOO 사업보고서

- ▶ 임직원 53명에게 총 261억 원 지급
- ▶ 1인당 평균 급여액은 5억 원에 근접
- ▶ 미등기임원 1인당 연봉도 10억 원을 넘어서며 조사대상 기업 중 최고치
- ▶ 미등기임원으로 재직하고 있는 OOO 회장에게 2020년 한 해 67억 원의 보수 지급
- ▶ 임원을 제외한 부장급 이하 일반 직원 평균 연봉 1억 6203만 원


이상치 처리(2/3)



특정 추세를 크게 벗어난 데이터



중앙값을 크게 벗어난 데이터



이상치 처리(3/3)

삭제



입력시
error거나 outlier수가 굉장히
적을 경우 그냥 삭제

대치



다른 값으로
변경

스케일링




보통 right skewed
(캐글에서 0.75이상)인 경우
log나 square root(제곱근)을 취함

Feature Engineering

데이터를 분석하거나 AI 알고리즘을 적용하기 위해
데이터의 도메인 지식을 활용,
변수를 가공하여 데이터를 비교적 간단명료하게 만드는 것

Feature = 각 데이터의 특징

Feature Engineering




데이터 가공/변환

Binning

연속형 변수를
범주형 변수로 만드는 방법

- ▶ 연속형 변수를 적절히 그룹을
지어주면 데이터를 이해하기가
더 쉬워짐




Binning

cut

vs

qcut

동일 **길이**로 나누기
사용자가 **구간값**을 직접 입력




1~5

6~10

11~15


동일 **개수**로 나누기
사용자가 **구간개수**를 입력



Scaling

숫자데이터간의 상대적 크기
차이를 제거하는 방법

- ▶ 각 컬럼에 들어있는 데이터의 상대적 크기에 따라 분석이나 모델링 결과가 달라짐



Normalization formula

$$X = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Scaling

StandardScaler()

- ▶ 각 특성의 평균을 0, 분산을 1로 스케일링함
즉, 데이터를 정규분포로 만듦

RobustScaler()

- ▶ 평균과 분산 대신에 중간값(정렬 시 중간에 있는 값)과 사분위값($\frac{1}{4}, \frac{3}{4}$ 에 위치한 값)을 사용함
- ▶ 전체 데이터와 아주 동떨어진 데이터(이상치)에 영향을 받지 않음

✓ RobustScaler란?

RobustScaler 는 중앙값(median) 과 사분위수(IQR) 를 기준으로 데이터를 정규화하는 방식입니다.
즉, 데이터의 중앙(median)을 0으로, IQR(Interquartile Range)을 1로 맞춥니다.

Scaling

MinMaxScaler()

- ▶ 각 특성이 0과 1 사이에 위치하도록 스케일링함
- ▶ 분류보다 회귀에 유용함

MaxAbsScaler()

- ▶ 각 특성의 절대값이 0과 1 사이가 되도록 스케일링함
즉, 모든 값은 -1과 1 사이로 표현되며,
데이터가 양수일 경우
MinMaxScaler와 같음

피쳐 공학(8/9)

StandardScaler

상황	이유
데이터가 정규분포(가우시안)에 가까울 때	평균 중심으로 분포
대부분의 머신러닝 알고리즘 (SVM, 로지스틱 회귀, 선형 회귀 등)	가중치 기반 학습 시 속도와 성능 개선
PCA, LDA 등 분산 기반 차원 축소	분산이 같은 기준으로 맞춰짐

MinMaxScaler

상황	이유
데이터의 최댓값과 최솟값 범위를 유지하고 싶을 때	예: 이미지 픽셀 (0255→01)
신경망(Neural Networks) 모델에서 입력값 정규화 시	0~1 범위가 학습 안정성에 유리
특성 값의 해석적 의미를 보존해야 할 때	값의 상대적인 크기를 유지

항목	StandardScaler()	MinMaxScaler()
스케일 기준	평균 0, 표준편차 1	최소 0, 최대 1
이상치 민감도	민감함	매우 민감함
정규분포 가정 필요	어느 정도 필요	불필요
신경망 사용	가능	더 적합

One Hot Encoding

하나의 데이터만 1,
나머지는 0으로 만들어 주는 방법

- ▶ 수치형/범주형/텍스트형 데이터 중 머신러닝이나 딥러닝 알고리즘은 수치로 된 데이터만 사용 가능
- ▶ 범주형/텍스트형 데이터를 기계가 가장 잘 이해 할 수 있도록 한 수치형 데이터 형태

거주지		서울	대전	부산
A	서울	1	0	0
B	대전	0	1	0
C	부산	0	0	1
D	대전	0	1	0
E	서울	1	0	0

감사합니다.