

Navigation시스템 도착 예측 모델링

- 도메인의 이해
- 분석대상 데이터 이해
- 데이터탐색(시각화)
- 데이터 전처리
- 파이썬 실습
- 인공지능 활용을 통한 데이터분석 및 전처리
- 머신러닝 모델링
- 딥러닝 모델링
- 파이썬 실습

모델링 프로세스



문제이해
및 분석

데이터수집
데이터병합
시각화
상관분석

결측치 처리
이상치 처리
변수 변환
스케일링

회귀분석
의사결정트리
랜덤포레스트
XGBoost
딥러닝

모델 평가
및 파라미터 조정


도메인 이해(1/3)

◆ 내비게이션 도착 예측 시간 정확도 향상

- 과거 주행 데이터를 기반으로 navigation 도착시간 예측 정확도 개선

[길 안내 구성요소]


구분	KT 원내비 용어	설명
주행정보	Session	운전자 기준에서 주행의 시작과 끝
경로정보	Route	경로 탐색이 이루어질 때마다 생성(재탐색 시마다 새로 생성)
도로정보	Link	주행경로의 최소단위(도로를 세분화)



도메인 이해(2/3)

[길 안내 구성요소]

구분	KT 원내비 용어	설명
주행정보	Session	운전자 기준에서 주행의 시작과 끝
경로정보	Route	경로 탐색이 이루어질 때마다 생성(재탐색 시마다 새로 생성)
도로정보	Link	주행경로의 최소단위(도로를 세분화)



경로정보

Index	RID	TIME_DEPARTUREDATE	TIME_ARRIVEDATE	_DISTANC	ET	ETA	ETAA
0	router-84875df7fc-b5nxc-7-20255166-0	2020-07-20 05:35:21.000	2020-07-20 05:55:22.599	12914	1201.53	987.625	82.197
1	router-84875df7fc-b5nxc-6-10888379-0	2020-07-20 05:55:22.000	2020-07-20 06:09:06.941	7483	823.817	855.934	96.1015
2	router-84875df7fc-cmkz9-7-45806143-0	2020-07-20 00:13:46.000	2020-07-20 00:22:32.909	8087	526.711	575.955	90.6507
3	router-84875df7fc-scxcj-7-47843617-0	2020-07-20 00:13:43.000	2020-07-20 00:28:42.729	10528	898.582	537.117	59.7738
4	router-84875df7fc-scxcj-3-20061505-0	2020-07-20 00:01:57.000	2020-07-20 00:17:58.169	10636	957.759	786.353	82.1034

추가정보1(경로 출발도시)

Index	RID	level1_pnu	level2_pnu
0	router-84875df7fc-b5nxc-2-2300503-0	경기도	고양시 덕양구
1	router-84875df7fc-scxcj-6-3976613-0	서울특별시	금천구
2	router-84875df7fc-52vz8-4-7281375-0	경기도	화성시
3	router-84875df7fc-scxcj-3-7147622-0	경기도	하남시
4	router-84875df7fc-cmkz9-4-7525466-0	서울특별시	서초구

추가정보2(경로의 신호등 갯수)

Index	RID	signaltype
0	router-84875df7fc-52vz8-0-10002399-0	22
1	router-84875df7fc-52vz8-0-10003032-0	2
2	router-84875df7fc-52vz8-0-10003142-0	20
3	router-84875df7fc-52vz8-0-10012957-0	7
4	router-84875df7fc-52vz8-0-10018039-0	24
5	router-84875df7fc-52vz8-0-10019426-0	16

도메인 이해(3/3)

목표변수 : ET(실주행시간, Estimated Time)

설명변수 : 거리(Distance) + ETA(과거 예측주행시간) + 신호등(Signal) + 요일 + 시간대 + 경유도시

목표변수

Index	RID	TIME_DEPARTUREDATE	TIME_ARRIVEDATE	_DISTANC	ET	ETA	ETAA	level1_pnu	level2_pnu	signaltype
0	router-84875df7fc-b5nxc-7-20255166-0	2020-07-20 05:35:21.000	2020-07-20 05:55:22.599	12914	1201.53	987.625	82.197	경기도	광명시	7
1	router-84875df7fc-b5nxc-6-10888379-0	2020-07-20 05:55:22.000	2020-07-20 06:09:06.941	7483	823.817	855.934	96.1015	서울특별시	영등포구	31
2	router-84875df7fc-cmkz9-7-45806143-0	2020-07-20 00:13:46.000	2020-07-20 00:22:32.909	8087	526.711	575.955	90.6507	경기도	김포시	6
3	router-84875df7fc-scxcj-7-47843617-0	2020-07-20 00:13:43.000	2020-07-20 00:28:42.729	10528	898.582	537.117	59.7738	경기도	광주시	2
4	router-84875df7fc-scxcj-3-20061505-0	2020-07-20 00:01:57.000	2020-07-20 00:17:58.169	10636	957.759	786.353	82.1034	경기도	안산시 상록구	28

*ET:실주행시간
**ETA:예측시간

$$ETAA = (1 - \frac{|ET - ETA|}{ET}) \times 100$$

ETAA(Estimated Time of Arrival Accuracy, 도착예측시간정확도)

실주행시간과 예측주행시간의 차이를 이용한 지표 : 값의 범위 : (0 ~ 100%) => 100에 가까울수록 정확한 예측

전처리 결과

Index	RID	TIME_DEPARTUREDATE	TIME_ARRIVEDATE	_DISTANC	ET	ETA	ETAA	level1_pnu	level2_pnu	signaltype
0	router-84875df7fc-b5nxc-7-20255166-0	2020-07-20 05:35:21.000	2020-07-20 05:55:22.599	12914	1201.53	987.625	82.197	경기도	광명시	7
1	router-84875df7fc-b5nxc-6-10888379-0	2020-07-20 05:55:22.000	2020-07-20 06:09:06.941	7483	823.817	855.934	96.1015	서울특별시	영등포구	31
2	router-84875df7fc-cmkz9-7-45806143-0	2020-07-20 00:13:46.000	2020-07-20 00:22:32.909	8087	526.711	575.955	90.6507	경기도	김포시	6
3	router-84875df7fc-scxcj-7-47843617-0	2020-07-20 00:13:43.000	2020-07-20 00:28:42.729	10528	898.582	537.117	59.7738	경기도	광주시	2
4	router-84875df7fc-scxcj-3-20061505-0	2020-07-20 00:01:57.000	2020-07-20 00:17:58.169	10636	957.759	786.353	82.1034	경기도	안산시 상록구	28

목표변수

df_target DataFrame (55421, 1)

navi_train_feature.csv

df_feature DataFrame (55421, 108)

Index	A_DISTANCE	ETA	signaltype	WEEKDAY_0	WEEKDAY_1	WEEKDAY_2	WEEKDAY_3	WEEKDAY_4	HOUR_0	HOUR_1	HOUR_2
0	0.826167	0.216722	0.0648148	1	0	0	0	0	0	0	0
1	0.373583	0.185241	0.287037	1	0	0	0	0	0	0	0
2	0.423017	0.118211	0.0555556	1	0	0	0	0	1	0	0

navi_train_target.csv

Index	ET
0	1201.53
1	823.817
2	526.711

navi_eval_feature.csv

eval_feature DataFrame (53732, 108)

Index	A_DISTANCE	ETA	signaltype	WEEKDAY_0	WEEKDAY_1	WEEKDAY_2	WEEKDAY_3	WEEKDAY_4	HOUR_0
0	0.148333	0.101265	0.166667	1	0	0	0	0	1
1	0.375417	0.0775983	0.00925926	1	0	0	0	0	1
2	0.94575	0.195422	0.166667	1	0	0	0	0	1

navi_eval_target.csv

eval_target DataFrame (53732, 1)

Index	ET
0	555.547
1	397.209
2	720.646

데이터분할

df_feature - DataFrame (55421, 108)

Index	A_DISTANCE	ETA	signaltype	VEHICLE
0	0.826167	0.216722	0.0648148	1
1	0.373583	0.185241	0.287037	1
2	0.423917	0.118311	0.0555556	1
3	0.627333	0.109026	0.0185185	1
4	0.636333	0.168607	0.259259	1

train_x - DataFrame train_x DataFrame (44336, 108)

Index	A_DISTANCE	ETA	signaltype	VEHICLE
50823	0.37575	0.20914	0.0648148	0
13793	0.103833	0.164964	0.157407	0
53541	0.0449167	0.103814	0.0185185	0

훈련용

test_x - DataFrame test_x DataFrame (11085, 108)

Index	A_DISTANCE	ETA	signaltype	VEHICLE
51147	0.615917	0.281116	0.166667	0
49616	0.0265	0.139759	0.037037	0
9314	0.207	0.177286	0.240741	0

테스트 용

df_target - DataFrame

Index	ET
0	1201.53
1	823.817
2	526.711
3	898.582
4	957.759

train_y - DataFrame

Index	ET
50823	1160
13793	623.274
53541	600.057

train_y DataFrame (44336, 1)

훈련용

test_y - DataFrame


Index	ET
51147	1540.5
49616	469.49
9314	667.531

test_y DataFrame (11085, 1)

테스트 용

df_target DataFrame (55421, 1)

머신러닝 기반 모델링(1/2)



머신러닝 주요 알고리즘 분류



RMSE

◆ RMSE(Root Mean Squared Error, 평균제곱근오차)

- 예측값이 숫자형인 경우의 평가지표
- 모델의 예측값이 실제값과 얼마나 차이 나는지(오차) 를 나타내는 지표
- “예측이 실제와 얼마나 정확하게 일치하나?”를 평균적인 거리로 측정

RMSE on Test set : 262.12790
MPE on Test set : 6.3% 오차 발생
R-squared Score on Test set : 0.73642

공식

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

MAE

기호	의미
y_i	실제값 (Observed Value)
$\hat{y}_i$	예측값 (Predicted Value)
n	데이터 개수

“오차의 제곱의 평균”을 구한 뒤 제곱근을 취한 값

예시

학생	실제 점수 (Y)	예측 점수 ($\hat{Y}$)	오차(e = Y - $\hat{Y}$)	오차제곱
A	80	78	+2	4
B	70	72	-2	4
C	90	85	+5	25
D	60	65	-5	25

$$RMSE = \sqrt{(4 + 4 + 25 + 25)/4} = \sqrt{14.5} \approx 3.81$$

⇒ RMSE = 3.81점

예측값은 실제 점수에서 평균적으로 약 ±3.8점 오차가 발생한다는 뜻

MPE

MPE 는 Mean Percentage Error (평균 백분율 오차) 의 약자

모델의 예측값이 실제값에 비해 평균적으로 몇 퍼센트나 차이 나는지를 보여주는 지표

$$MPE = \frac{100}{n} \sum_{i=1}^n \frac{y_i - \hat{y}_i}{y_i}$$

RMSE on Test set : 262.12790
MPE on Test set : 6.3% 오차 발생
R-squared Score on Test set : 0.73642

실제값(y)	예측값($\hat{y}$)	오차($y - \hat{y}$)	비율($(y - \hat{y})/y$)	(%)
100	90	+10	+0.10	+10%
200	220	-20	-0.10	-10%
300	270	+30	+0.10	+10%

$$MPE = \frac{(+10\% - \downarrow -10\% + 10\%)}{3} = +3.3\%$$

R제곱(R-Squared)

회귀모형 진단


1 적합도 검정(Goodness-of-fit Test)

- 회귀모형이 데이터를 얼마나 잘 설명하는가 → 결정계수 R^2


$$R^2 = \frac{SSR}{SST}$$

- SSR (Regression Sum of Squares): 회귀로 설명되는 변동
- SSE (Error Sum of Squares): 회귀로 설명되지 않는 변동
- SST (Total Sum of Squares): 전체 변동

범위: 0~1 (1에 가까울수록 좋은 모델)



RMSE on Test set : 262.12790
MPE on Test set : 6.3% 오차 발생
R-squared Score on Test set : 0.73642



딥러닝 기반 모델링(1/2)

Index	A_DISTANCE	ETA	signaltype	V
50823	0.37575	0.20914	0.0648148	0
13793	0.103833	0.164964	0.157407	0
53541	0.0449167	0.103814	0.0185185	0


Index	A_DISTANCE	ETA	signality
51147	0.615917	0.281116	0.16666
49616	0.0265	0.139759	0.03703
9314	0.207	0.177286	0.24074

Index	ET
51147	1540.5
49616	469.49
9314	667.531

Index	ET
50823	1160
13793	623.274
53541	600.057

모델링 (학습)

Deep Learning



Input Layer


Hidden Layer

Output Layer

모델

예측결과

	0
0	1366.47
1	651.098
2	853.242




성능평가

mae

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

딥러닝 기반 모델링(2/2)



파이썬 실습

파이썬 가상환경 생성 및 텐서플로 등 설치

```
# 아나콘다 Power Shell을 관리자모드로 실행 후,다음 명령어를 순차적으로 입력
conda create -n tfenv python=3.10
conda activate tfenv
pip install tensorflow
pip install numpy==1.26.4
pip install pandas
pip install matplotlib
pip install seaborn
pip install scikit-learn
pip install xgboost
pip install spyder
spyder 실행
```

감사합니다.